



Universidad
Nacional
de Loja

Universidad Nacional de Loja

Facultad de la Energía, las Industrias y los Recursos Naturales
No Renovables

Carrera de Computación

Desarrollo de un modelo de vision transformer para
la clasificación de granos de café verde arábico.

Development of a vision transformer model for the
classification of green arabica coffee beans.

Metodología de la Investigación en Computación.

AUTOR:

Bryan Gustavo Troya Velez

TUTOR:

Prof. Luis Chamba-Eras

Loja, Ecuador

2026

Declaración de uso de IA Generativa

Yo, **Bryan Gustavo Troya Velez**, en calidad de autor, declaro de manera transparente y responsable el uso de herramientas de Inteligencia Artificial Generativa (IAG) durante el desarrollo del presente trabajo, en conformidad con los principios de integridad académica, ética investigativa y buenas prácticas en el uso de tecnologías emergentes.

1. Alcance del uso de IA generativa

El uso de herramientas de IAG se ha limitado a funciones de apoyo, sin sustituir el juicio crítico ni la autoría intelectual del autor. En particular, se han utilizado para:

- Mejora de redacción y estilo académico.
- Generación de ideas preliminares.
- Apoyo en la estructuración del documento.
- Asistencia en traducción técnica.

2. Clasificación del uso según GAIDeT

De acuerdo con la taxonomía GAIDeT, el uso de IA generativa en este trabajo se clasifica en:

- **Nivel 1 – Asistencia Lingüística:** Corrección gramatical y mejora de claridad.
- **Nivel 2 – Apoyo en Ideación:** Generación de ideas y esquemas conceptuales.
- **Nivel 3 – Asistencia Técnica:** Apoyo en generación de código y explicaciones técnicas.

No se ha utilizado IA generativa para la generación autónoma de resultados ni para sustituir el análisis crítico del autor.

3. Validación y responsabilidad

Todo contenido asistido por IA ha sido revisado, validado y adaptado por el autor, quien asume la responsabilidad total sobre la calidad, veracidad y originalidad del trabajo.

4. Herramientas utilizadas

Se emplearon modelos de lenguaje (LLMs) y herramientas de asistencia técnica para redacción, estructuración y apoyo conceptual.

5. Consideraciones éticas

El uso de IA se realizó respetando principios de honestidad académica, normativas institucionales de la Universidad Nacional de Loja y buenas prácticas internacionales.

6. Declaración final

Declaro que el uso de IA generativa ha sido ético, transparente y complementario, sin comprometer la autoría ni la integridad académica del presente trabajo.

Loja, Ecuador, [Fecha]

Bryan Gustavo Troya Velez
Autor

Índice General

Declaración de uso de IA Generativa	1
Índice de Algoritmos	6
Índice de Códigos	7
Índice de Ecuaciones	8
Índice de Anexos	9
1 Título	10
2 Resumen	11
3 Abstract	12
4 Introducción	13
4.1 Variables de la Investigación	14
4.1.1 Investigación Exploratoria	14
4.1.2 Investigación Descriptiva	14
4.1.3 Investigación Aplicada	15
4.1.4 Investigación Experimental	15
4.2 Objetivos de la Investigación	15
4.2.1 Investigación Exploratoria	15
4.2.2 Investigación Descriptiva	16
4.2.3 Investigación Aplicada	16
4.2.4 Investigación Experimental	16
5 Marco teórico	18

Índice de Tablas

4.1 Preguntas de investigación	13
--	----

Índice de Figuras

Índice de Algoritmos

Índice de Códigos

Índice de Ecuaciones

Índice de Anexos

- **Anexo 1.** (Título del Anexo 1) p. x
- **Anexo 2.** (Título del Anexo 2) p. y

1. Título

Desarrollo de un modelo de vision transformer para la clasificación de granos de café verde arábico.

2. Resumen

(Resumen en español, 250–300 palabras).

3. Abstract

(Abstract en inglés; 250–300 words).

4. Introducción

(Contexto, problema, objetivos).

Este documento presenta una plantilla institucional de la UNL con formato IEEE para citas y referencias [?].

Tabla 4.1: Preguntas de investigación

Tipo de Pregunta de Investigación	Pregunta de Investigación
Investigación Exploratoria	¿Cómo funciona AdaBoost en la mejora de clasificadores débiles? Liu2025
Investigación Descriptiva	¿Cuál es el panorama actual de las técnicas de hibridación entre algoritmos de ensamble (Boosting) y arquitecturas de aprendizaje profundo (como LSTM o CNN) utilizadas para la detección de anomalías en entornos financieros e industriales según la literatura técnica de los últimos tres años?
Investigación Aplicada	¿Cómo se puede optimizar la detección de fraude en transacciones financieras secuenciales mediante la implementación de un marco híbrido que integre redes de memoria a largo plazo (LSTM) y algoritmos AdaBoost para reducir el riesgo de sobreajuste?
Investigación Experimental	¿Cuál es el impacto de la incorporación del Coeficiente de Diversidad (medida de Doble Falla) en la métrica de rendimiento AUC-ROC del algoritmo AdaBoost, en comparación con el AdaBoost tradicional, cuando se procesan conjuntos de datos de tarjetas de crédito con altos niveles de ruido y valores atípicos?

4.1. Variables de la Investigación

4.1.1. Investigación Exploratoria

Este enfoque se centra en el mecanismo teórico fundamental del algoritmo para comprender su funcionamiento interno.

- **Variable Independiente (Entrada):** Conjunto de aprendices débiles (h_t) o hipótesis base que rinden ligeramente mejor que el azar.
- **Variables de Proceso (Mecanismo):**
 - Distribución de pesos de las muestras (D_t): valores que determinan la importancia de cada dato en cada iteración.
 - Tasa de error ponderada (ϵ_t): métrica que evalúa el desempeño del clasificador base respecto a la distribución actual.
 - Coeficiente de importancia (α_t): peso asignado al clasificador débil en la decisión final según su precisión.
- **Variable Dependiente (Resultado):** El aprendiz fuerte final ($H(x)$) resultante de la combinación lineal ponderada.

4.1.2. Investigación Descriptiva

Busca caracterizar el estado actual de la tecnología y los factores del entorno sin intervenir en ellos.

- **Variables de Categorización:**
 - Tipos de arquitecturas híbridas: modelos como AdaBoost-LSTM o CNN+AdaBoost.
 - Dominios de aplicación: sectores industrial, financiero, judicial y procesamiento de lenguaje natural.
- **Variables de Caracterización del Problema:**
 - Naturaleza de los datos: ruido, dependencias temporales y desbalance de clases.
 - Factores de influencia: variables relevantes como “lesión grave” o “arrepentimiento” en contextos específicos.

4.1.3. Investigación Aplicada

Se enfoca en la implementación práctica de una solución para un problema real de clasificación.

- **Variables Independientes (Datos de Entrada):**
 - Atributos transaccionales: tiempo, monto y variables anonimizadas (V_1-V_{28}).
 - Datos de sensores: acelerómetro (a_x, a_y, a_z) y giroscopio (g_x, g_y, g_z).
- **Variables Operativas (Modelo):** Hiperparámetros del optimizador Adam (tasa de aprendizaje α , parámetros β_1, β_2) y configuración de la red LSTM.
- **Variables Dependientes (Métricas de Éxito):** Accuracy, Recall, Especificidad y F1-Score.

4.1.4. Investigación Experimental

Este tipo de investigación manipula una variable técnica para medir un impacto estadístico bajo condiciones controladas.

- **Variable Independiente (Intervención):** Incorporación del coeficiente de diversidad basado en la medida de Doble Falla (DF).
- **Variable de Control:** Algoritmo AdaBoost tradicional bajo los mismos parámetros.
- **Variable Moderadora (Condiciones):** Niveles de ruido blanco aditivo (0% a 100%).
- **Variable Dependiente (Efecto):** Variación en AUC-ROC y reducción del error de generalización.

4.2. Objetivos de la Investigación

4.2.1. Investigación Exploratoria

Objetivo General: Analizar el mecanismo fundamental del algoritmo AdaBoost para comprender la transformación de clasificadores débiles en modelos robustos mediante la reponderación iterativa de errores.

Objetivos Específicos:

- Describir el proceso matemático de inicialización de pesos y la actualización dinámica de las muestras mal clasificadas en cada iteración.

- Identificar la función del coeficiente de importancia (α_t) en la construcción de la frontera de decisión del clasificador fuerte final.
- Comparar el rendimiento de la votación ponderada frente a la votación simple en la reducción del sesgo del modelo.

4.2.2. Investigación Descriptiva

Objetivo General: Caracterizar las tendencias actuales en la integración de algoritmos de Boosting con redes neuronales profundas para el diagnóstico de anomalías en sistemas industriales y financieros según la literatura científica reciente.

Objetivos Específicos:

- Documentar los casos de uso predominantes de arquitecturas híbridas como AdaBoost-LSTM y CNN-AdaBoost reportados en los últimos tres años.
- Categorizar las ventajas técnicas de los modelos híbridos en términos de captura de dependencias temporales y extracción de características complejas.
- Sintetizar las limitaciones críticas identificadas, tales como el costo computacional y la sensibilidad extrema al ruido en estos modelos avanzados.

4.2.3. Investigación Aplicada

Objetivo General: Desarrollar un marco híbrido de aprendizaje por conjuntos que combine AdaBoost con redes LSTM para mejorar la precisión y robustez en la detección de fraudes dentro de flujos de datos transaccionales secuenciales.

Objetivos Específicos:

- Implementar unidades de memoria (LSTM) para capturar los patrones temporales de comportamientos fraudulentos.
- Aplicar el mecanismo de reponderación dinámica para priorizar las transacciones de difícil clasificación y mitigar el desbalance de clases.
- Validar la solución propuesta utilizando métricas de desempeño como Precision, Recall y AUC sobre conjuntos de datos reales.

4.2.4. Investigación Experimental

Objetivo General: Evaluar el efecto de la incorporación de la métrica de Doble Falla (DF) como coeficiente de diversidad en el rendimiento estadístico del algoritmo AdaBoost en entornos de datos con alta presencia de ruido.

Objetivos Específicos:

- Diseñar un protocolo experimental que compare el AdaBoost convencional frente a variantes que integran mecanismos de diversidad y aprendizaje a ritmo propio (SPL).
- Cuantificar la variación en las tasas de error y el valor AUC-ROC bajo diferentes niveles controlados de ruido.
- Determinar estadísticamente si la optimización de la diversidad entre clasificadores base reduce el riesgo de sobreajuste.

5. Marco teórico

(Antecedentes, definiciones, variables, citas según IEEE).

La estandarización de reportes técnicos es fundamental en computación [?].

El uso de referencias IEEE permite trazabilidad científica [?].

[a4paper,10pt]article

[utf8]inputenc [T1]fontenc geometry pdfscape tabularx array

margin=1cm

#	Referencia	Año	Base	IA	Problema	Objetivo	Metodología	Dataset
1	H. H. Sulimani, "AdaBoost-LSTM," IEEE Access, 2025	2025	IEEE	AdaBoost + LSTM	Fraude financiero	Mejorar detección	Boosting + LSTM	Datos financieros
2	S. Liu et al., "Sentencing Prediction Based on AdaBoost," ACM, 2026	2026	ACM	AdaBoost	Predicción judicial	Incrementar precisión	Ensemble Learning	Datos legales
3	W. Muhammad et al., "Intelligent Troubleshooting," IEEE Access, 2024	2024	IEEE	Ensemble	Diagnóstico industrial	Detectar fallas	Boosting industrial	Sensores
4	Y. Wang and L. Feng, "Bagging-Based Ensemble Learning," ACM, 2025	2025	ACM	Bagging	Clasificación textual	Mejorar clasificación	Bagging	Textos
5	W. Ning et al., "AMWS-PLAdaBoost," IEEE Access, 2023	2023	IEEE	AdaBoost	Fraude financiero	Incrementar precisión	Boosting diverso	Datos financieros
6	A. Ahmed et al., "Ensemble Methods," Springer, 2023	2023	Springer	Ensemble	Clasificación	Analizar ensembles	Comparación ensemble	Datasets variados
7	A. Sayeri et al., "Spam Detection Using AdaBoost," IEEE, 2023	2023	IEEE	AdaBoost	Spam	Reducir errores	Boosting iterativo	Correos
8	K. Nirmal et al., "Hybrid AdaBoost IDS," IEEE, 2024	2024	IEEE	AdaBoost híbrido	Intrusiones	Mejorar seguridad	Modelo híbrido	Red
9	M. Carreira-Perpiñán, "Ensemble Techniques," ACM, 2022	2022	ACM	Ensemble	Clasificación	Comparar ensembles	Revisión teórica	Datasets variados
10	P. Singh and R. Sharma, "Medical Diagnosis System," Springer, 2023	2023	Springer	AdaBoost	Diagnóstico médico	Incrementar precisión	Clasificación iterativa	Datos clínicos
11	M. Tawfik and A. Zayed, "Smart Systems," ScienceDirect, 2024	2024	ScienceDirect	Ensemble	Sistemas inteligentes	Optimizar predicción	Comparación boosting	IoT
12	H. Xu, "Sonar Signal Classification," IEEE, 2021	2021	IEEE	AdaBoost	Clasificación sonar	Mejorar exactitud	Boosting	Sonar
13	Y. Xu et al., "GAN-Based Ensemble Learning," ACM, 2025	2025	ACM	GAN + Ensemble	Clasificación	Mejorar robustez	GAN + boosting	Datos sintéticos
14	T. Tiantian et al., "Boosting-Based Classification," Springer, 2023	2023	Springer	Boosting	Clasificación	Optimizar modelos	Boosting iterativo	Datos estructurados
15	J. Zhang et al., "Adaptive Ensemble Classification," IEEE, 2024	2024	IEEE	AdaBoost adaptativo	Clasificación	Mejorar adaptabilidad	Reponderación dinámica	Datos generados
16	V. Reddy et al., "Fraud Detection Using Ensemble Learning," ScienceDirect, 2024	2024	ScienceDirect	Ensemble	Fraude financiero	Comparar ensembles	Boosting vs bagging	Datos financieros
17	M. Rahman et al., "Ensemble Models," Springer, 2023	2023	Springer	Ensemble	Clasificación	Optimizar modelos	Combinación ensembles	Datasets
18	Y. Freund and R. Schapire, "Application to Boosting," JCSS, 1997	1997	ScienceDirect	AdaBoost	Boosting teórico	Introducir AdaBoost	Modelo matemático	Teórico
19	T. G. Dietterich, "Ensemble Methods in ML," Springer, 2000	2000	Springer	Ensemble	Clasificación	Explicar ensembles	Análisis comparativo	Datasets variados
20	A. Tharwat, "Classification Assessment Methods," 2021	2021	ScienceDirect	Ensemble	Evaluación clasificación	Analizar métricas	Comparación métricas	Datasets