

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
1.	Funcionamiento de AdaBoost en la Potenciación y Mejora de Clasificadores Débiles.	3
1.1.	Introducción	3
1.2.	Fundamentos Teóricos	4
1.2.1.	El Concepto de Boosting y la Transformación de Aprendices Débiles . . .	4
1.2.2.	Proceso Iterativo y Actualización de Pesos	4
1.2.3.	Proceso Iterativo y Actualización de Pesos	4
1.2.4.	Función de Pérdida Exponencial y Minimización del Error	5
1.2.5.	Construcción del Clasificador Fuerte	5
1.2.6.	Complejidad Computacional y Escalabilidad	5
1.2.7.	Variantes del Algoritmo AdaBoost	5
1.2.8.	Optimización de la Función de Actualización de Pesos y Reglas de Iteración	6
1.3.	Metodología y Análisis de la Literatura	6
1.3.1.	Hibridación con Aprendizaje Profundo (Deep Learning)	6
1.3.2.	Estrategias ante el Ruido y los Valores Atípicos	7
1.3.3.	Gestión del Desbalance de Clases y Diversidad	7
1.3.4.	Optimizaciones Metaheurísticas y Evolutivas	8
1.3.5.	Aplicaciones Transversales y Desempeño	8
1.3.6.	Comparación de AdaBoost con Otros Métodos Ensemble	9
1.3.7.	Tendencias de Investigación y Líneas Futuras	9
1.3.8.	AdaBoost en Aprendizaje Semisupervisado y Optimización Metaheurística	9
1.3.9.	Uso de Broad Learning Systems (BLS) como Aprendices Débiles	10
1.3.10.	Aplicaciones en Procesamiento de Señales de Un Bit y Sensado Comprimido	10
1.3.11.	Justicia Algorítmica y Reducción de Sesgo en el Boosting	10
1.3.12.	Aplicaciones en Procesamiento de Lenguaje Natural (NLP)	10
1.3.13.	Técnica de votación	10
1.3.14.	Resumen de Variables Clave	11
1.4.	Conclusiones	12

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 1

Funcionamiento de AdaBoost en la Potenciación y Mejora de Clasificadores Débiles.

Autor: Bryan Gustavo Troya Velez (bryan.troya@unl.edu.ec)
Técnica asignada: Adaboost

1.1. Introducción

En el panorama actual de la Inteligencia Artificial (IA), el procesamiento de volúmenes masivos de datos heterogéneos ha impulsado la necesidad de desarrollar algoritmos que no solo logren altos niveles de precisión, sino que también presenten robustez y capacidad de generalización [1, 2]. El aprendizaje por conjuntos (ensemble learning) se ha consolidado como una de las estrategias más eficaces para superar las limitaciones intrínsecas de los modelos individuales, permitiendo reducir el error de generalización, el sesgo y la varianza mediante la combinación de múltiples clasificadores. Dentro de esta categoría, el algoritmo AdaBoost (Adaptive Boosting) destaca como un pilar fundamental debido a su capacidad teórica para transformar un conjunto de "aprendices débiles"—modelos cuyo desempeño es apenas superior al azar— en un clasificador fuerte de alta precisión [3, 4].

El funcionamiento de AdaBoost se fundamenta en un proceso iterativo y secuencial de reponderación dinámica. A diferencia de los métodos de ensamble paralelos como el bagging, AdaBoost ajusta el enfoque de cada nuevo aprendiz en función de los errores cometidos por sus predecesores, obligando al sistema a concentrar su capacidad de aprendizaje en las muestras más difíciles de clasificar [5, 6]. Esta versatilidad ha permitido su aplicación en dominios críticos como la detección de fraude financiero, el diagnóstico de fallos industriales, la predicción de sentencias judiciales y la identificación de trastornos de salud mental [7–10].

No obstante, la literatura técnica identifica desafíos persistentes que limitan la eficacia del AdaBoost tradicional, tales como su sensibilidad extrema al ruido y a los valores atípicos (outliers), el riesgo de sobreajuste (overfitting) en conjuntos de datos complejos y las dificultades ante el desbalance de clases. Este trabajo analiza los mecanismos de optimización propuestos en investigaciones recientes, desde la hibridación con arquitecturas de aprendizaje profundo hasta la integración de estrategias de aprendizaje a ritmo propio (self-paced learning), con el fin de proporcionar una visión técnica exhaustiva sobre la evolución de este algoritmo en los sistemas inteligentes modernos [11, 12]

1.2. Fundamentos Teóricos

1.2.1. El Concepto de Boosting y la Transformación de Aprendices Débiles

La premisa central del *boosting* es la construcción de una función de clasificación fuerte mediante la adición secuencial de funciones de clasificación más simples o “débiles”. Un aprendiz débil se define formalmente como aquel que posee una tasa de error ligeramente inferior al 50 por ciento en un problema de clasificación binaria. AdaBoost utiliza un mecanismo de reponderación que garantiza que cada nuevo clasificador base se entrene sobre una distribución de datos que prioriza las instancias mal clasificadas previamente [3] [13].

1.2.2. Proceso Iterativo y Actualización de Pesos

El algoritmo comienza asignando pesos uniformes a todas las muestras del conjunto de entrenamiento:

$$D_1(i) = \frac{1}{N} \quad (1.1)$$

donde N representa el número total de muestras. En cada iteración t , se selecciona un clasificador débil h_t que minimiza el error de clasificación ponderado ϵ_t .

La importancia del clasificador en la decisión final se calcula mediante:

$$\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \epsilon_t}{\epsilon_t} \right) \quad (1.2)$$

Tras evaluar el desempeño de h_t , el algoritmo actualiza la distribución de pesos. Las muestras clasificadas correctamente disminuyen su relevancia, mientras que las clasificadas erróneamente reciben un incremento exponencial en su peso. Este ciclo se repite hasta alcanzar un número predefinido de iteraciones o hasta que el error converg [3] [5].

Finalmente, el clasificador fuerte se obtiene mediante una votación ponderada de todos los aprendices débiles:

$$H(x) = \text{sign} \left(\sum_{t=1}^T \alpha_t h_t(x) \right) \quad (1.3)$$

1.2.3. Proceso Iterativo y Actualización de Pesos

Dada una base de datos con N muestras, el algoritmo inicializa una distribución uniforme de pesos según la Ecuación 1.5. Durante cada iteración:

1. Se entrena un clasificador débil h_t minimizando el error de clasificación ponderado ϵ_t , correspondiente a la suma de los pesos de las instancias clasificadas incorrectamente.
2. Se calcula el coeficiente de importancia α_t mediante la Ecuación ???. Este valor determina el peso de voto del clasificador dentro del modelo final; cuanto menor es el error, mayor es su influencia.
3. Se actualizan los pesos de las muestras para la iteración siguiente. Las observaciones mal clasificadas incrementan su importancia, mientras que las correctamente clasificadas reducen su peso relativo.
4. Los pesos se normalizan mediante un factor de normalización Z_t para garantizar que la suma total de probabilidades sea igual a uno.

1.2.4. Función de Pérdida Exponencial y Minimización del Error

AdaBoost puede interpretarse como un modelo aditivo secuencial que busca minimizar una función de pérdida exponencial definida como:

$$L(y, F(x)) = \exp(-yF(x)) \quad (1.4)$$

Este enfoque penaliza de manera significativa los errores de clasificación, obligando a los clasificadores posteriores a concentrarse en las regiones más complejas del espacio de datos. La optimización de esta función es convexa, lo que facilita la convergencia hacia soluciones óptimas en cada etapa del entrenamiento. Sin embargo, esta característica también incrementa la sensibilidad del algoritmo frente a datos ruidosos o etiquetas incorrectas [5] [12].

1.2.5. Construcción del Clasificador Fuerte

Tras completar T iteraciones, el clasificador fuerte se construye mediante la combinación lineal ponderada de todos los aprendices débiles:

$$H(x) = \text{sign} \left(\sum_{t=1}^T \alpha_t h_t(x) \right) \quad (1.5)$$

Este mecanismo de votación ponderada permite reducir el sesgo del modelo sin incrementar significativamente la varianza, obteniendo fronteras de decisión robustas incluso en problemas de clasificación no lineal.

1.2.6. Complejidad Computacional y Escalabilidad

La eficiencia computacional de AdaBoost depende tanto del tamaño del conjunto de datos como de la complejidad de los clasificadores base utilizados. Diversos estudios reportan que, en ciertas aplicaciones especializadas, AdaBoost presenta tiempos de entrenamiento inferiores a los de Random Forest debido a su estructura secuencial simplificada [14] [1]. No obstante, en conjuntos de datos masivos, como aquellos relacionados con visión por computadora o análisis documental, los tiempos de entrenamiento pueden incrementarse considerablemente cuando se emplea un gran número de estimadores.

En arquitecturas híbridas que integran AdaBoost con modelos de aprendizaje profundo, la complejidad computacional aumenta debido al número de parámetros entrenables y a la necesidad de recursos de procesamiento más avanzados [7] [15].

1.2.7. Variantes del Algoritmo AdaBoost

Con el objetivo de reducir las limitaciones del algoritmo clásico, la literatura ha propuesto múltiples variantes especializadas:

- **AMWSPLAdaBoost:** incorpora estrategias de *self-paced learning* para reducir progresivamente la influencia de muestras ruidosas durante las primeras etapas del entrenamiento [5].
- **AdaBoost-LSTM y BP-AdaBoost:** combinan AdaBoost con redes neuronales profundas, permitiendo modelar dependencias temporales y relaciones no lineales complejas [7] [16].
- **CS-AdaBoost:** integra técnicas de *compressed sensing* para la estimación eficiente de señales con restricciones de cuantización [17].

- **SMOTEHashBoost**: combina sobremuestreo sintético mediante SMOTE con técnicas de hashing para mejorar el desempeño en conjuntos de datos con desbalance extremo de clases [6].

Estas variantes evidencian la evolución del algoritmo hacia enfoques más robustos, capaces de abordar desafíos asociados al ruido, la complejidad de los datos y la escalabilidad computacional.

1.2.8. Optimización de la Función de Actualización de Pesos y Reglas de Iteración

Investigaciones recientes sugieren que la actualización exponencial estándar de AdaBoost puede refinarse para casos de uso específicos. Por ejemplo, en el procesamiento de imágenes de sonar, se ha propuesto una función de peso seccional que aumenta lentamente entre los valores de error 0 y 0.8, pero cambia linealmente entre 0.8 y 1.

Este enfoque permite que las muestras fáciles reciban una atención uniforme al inicio, mientras que las muestras críticas se distinguen con mayor eficacia en etapas avanzadas. Asimismo, se han introducido reglas de iteración mejoradas donde, si el error de entrenamiento llega a cero, el peso del clasificador se fija en 1 y el entrenamiento termina, reduciendo significativamente el tiempo de cómputo y el impacto de clasificadores base redundantes [18].

1.3. Metodología y Análisis de la Literatura

A través de la metodología de jerarquización científica y la extracción sistemática de datos provenientes de artículos indexados en bases de datos de alto impacto, se analizaron las principales contribuciones relacionadas con la optimización del algoritmo AdaBoost. El análisis permitió identificar líneas de investigación orientadas a la mejora de la precisión, robustez y escalabilidad del algoritmo mediante técnicas de aprendizaje profundo, estrategias para el tratamiento del ruido, métodos de balanceo de clases y algoritmos de optimización avanzados.

1.3.1. Hibridación con Aprendizaje Profundo (Deep Learning)

Una de las tendencias más relevantes en la evolución de AdaBoost consiste en su integración con redes neuronales profundas para capturar dependencias complejas presentes en los datos. Entre los enfoques más estudiados se encuentra AdaBoost-LSTM, que combina el mecanismo de reponderación iterativa con redes de memoria a largo plazo (*Long Short-Term Memory*, *LSTM*) para la detección de fraude en secuencias temporales. Esta arquitectura permite que cada unidad de memoria se concentre en patrones difíciles de clasificar [7].

De manera similar, arquitecturas híbridas como CNN-AdaBoost emplean redes neuronales convolucionales (*Convolutional Neural Networks*, *CNN*) como extractores automáticos de características de alta dimensionalidad, mientras que AdaBoost actúa como clasificador final. Esta combinación ha demostrado mejorar la robustez frente al ruido y la variabilidad de los datos en aplicaciones industriales [19] [8].

En el ámbito de la detección de anomalías, diversos estudios han propuesto la integración de Redes Generativas Antagónicas (*Generative Adversarial Networks*, *GAN*) con AdaBoost. En estos sistemas, los generadores aprenden la distribución de los datos normales y AdaBoost combina múltiples detectores basados en errores de reconstrucción, mejorando la detección de anomalías en series temporales de larga duración [15].

La literatura actual destaca que AdaBoost ya no solo se usa con árboles de decisión simples, sino como un marco para potenciar redes neuronales complejas: Marco ABCN (CNN + AdaBoost): En el mantenimiento industrial de sierras de cinta, se utiliza una CNN 1D para la extracción automática de características temporales de sensores IoT, mientras que AdaBoost

actúa como el clasificador robusto final, logrando precisiones superiores al 96 por ciento incluso con bajas tasas de muestreo (5 Hz). AdaBoost-LSTM: Para datos secuenciales financieros, las unidades LSTM capturan las dependencias temporales de las transacciones, y el mecanismo de reponderación de AdaBoost fuerza al modelo a concentrarse en los patrones de fraude más difíciles de detectar [15].

1.3.2. Estrategias ante el Ruido y los Valores Atípicos

Una limitación ampliamente documentada de AdaBoost es su tendencia a asignar pesos elevados a muestras ruidosas o valores atípicos (*outliers*), lo que puede afectar negativamente la capacidad de generalización del modelo. Para abordar este problema, se han desarrollado variantes basadas en el Aprendizaje a Ritmo Propio (*Self-Paced Learning, SPL*) [11, 12].

El modelo AMWSPLAdaBoost incorpora mecanismos de regularización que permiten reducir progresivamente la influencia de observaciones poco confiables durante las etapas iniciales del entrenamiento. De esta manera, el algoritmo prioriza inicialmente los ejemplos más representativos antes de considerar muestras complejas o potencialmente erróneas [5].

Otros enfoques modifican directamente las funciones de pérdida o las reglas de actualización de pesos mediante umbrales adaptativos. En aplicaciones de procesamiento de imágenes sonar y monitoreo geológico, estas estrategias han demostrado reducir el sobreajuste y mejorar la estabilidad del modelo frente a perturbaciones externas [5].

Un avance significativo en la optimización de AdaBoost es la integración del Aprendizaje a Ritmo Propio (SPL). Este mecanismo permite que el algoritmo no asigne pesos masivos a los errores desde el inicio, sino que aprenda primero de las muestras "fáciles" y descarte gradualmente el ruido ambiental que suele confundir al AdaBoost tradicional [8].

Innovación técnica: Se ha propuesto la reconstrucción de la función objetivo mediante un término regularizador SPL que mitiga el sobreajuste en entornos con datos muy sucios, como en la detección de fraudes [20].

Diversidad del clasificador: Para mejorar la generalización, se utiliza el coeficiente de Doble Falla (DF) para medir qué tan diferentes son los clasificadores base entre sí, asegurando que el ensamble final sea diverso y no solo preciso de forma redundante [12].

1.3.3. Gestión del Desbalance de Clases y Diversidad

El desbalance de clases representa uno de los principales desafíos en aplicaciones como la detección de fraude, el diagnóstico médico y la detección de intrusiones. Para enfrentar este problema, diversos trabajos combinan AdaBoost con técnicas de remuestreo como SMOTE (*Synthetic Minority Over-sampling Technique*) y ENN (*Edited Nearest Neighbor*) [4] [21].

Entre las propuestas más destacadas se encuentra SMOTEHashBoost, algoritmo que utiliza sobremuestreo sintético para la clase minoritaria y funciones hash para generar subconjuntos diversos de la clase mayoritaria. Esta estrategia permite entrenar clasificadores débiles sobre conjuntos de datos más equilibrados y representativos [6].

La literatura también destaca la importancia de la diversidad entre clasificadores. Algunas investigaciones incorporan métricas como la medida de Doble Falla (*Double Fault*) directamente en el cálculo del peso de cada clasificador, equilibrando precisión individual y diversidad dentro del ensamble. Asimismo, modelos híbridos como Twined Ensemble combinan AdaBoost, Random Forest y Gradient Boosting para incrementar la capacidad de detección de eventos poco frecuentes [22].

Para resolver el sesgo hacia la clase mayoritaria, se han desarrollado marcos como SMO-TEHashBoost.

Funcionamiento: Este método integra el sobremuestreo sintético (SMOTE) con técnicas de hashing para reducir la duplicidad de datos en la clase mayoritaria y PCA para la reducción de dimensionalidad.

Resultado: Esto permite que cada clasificador débil del proceso de boosting sea entrenado en un subconjunto de datos perfectamente balanceado, mejorando métricas críticas como el F1-Score y el Recall en la detección de intrusiones y fallos de software [22].

1.3.4. Optimizaciones Metaheurísticas y Evolutivas

La optimización de hiperparámetros y la selección de características han motivado la incorporación de algoritmos evolutivos en el diseño de sistemas basados en AdaBoost. Un ejemplo representativo es EVAdaBoost, que emplea algoritmos cuántico-evolutivos para seleccionar subconjuntos óptimos de características y posteriormente aplica técnicas de poda evolutiva para eliminar clasificadores redundantes [10].

Otros estudios integran el algoritmo de Búsqueda de Gorrión (*Sparrow Search Algorithm, SSA*) junto con funciones seno-coseno para optimizar los parámetros de clasificadores semisupervisados basados en máquinas de vectores de soporte. Estas estrategias permiten mejorar simultáneamente la precisión y la eficiencia computacional en tareas complejas de clasificación médica y análisis de imágenes [23].

En la predicción de reacciones adversas a medicamentos (ADR) y el diagnóstico de diabetes, AdaBoost se ha optimizado mediante el ajuste de pesos adaptativos para manejar el desbalance de clases extremo. Comparativa técnica: Aunque modelos como SVM pueden ser superiores en el manejo de huellas químicas específicas (fingerprints), AdaBoost destaca por su capacidad de potenciar clasificadores débiles en tareas de clasificación binaria donde los datos de la clase minoritaria son escasos. Optimización Bayesiana: Se han implementado variantes como el GentleBoost optimizado por Bayes para refinar los hiperparámetros del ensamble, mejorando la precisión diagnóstica en enfermedades cardiovasculares y cáncer de pulmón [14].

1.3.5. Aplicaciones Transversales y Desempeño

La versatilidad de AdaBoost ha permitido su aplicación en múltiples dominios:

- **Ámbito judicial:** predicción de sentencias y análisis de factores asociados a lesiones intencionales [9].
- **Sector energético:** estimación del estado de carga de baterías de litio y detección de fraude eléctrico en redes inteligentes [16] [19].
- **Geofísica:** identificación de anomalías ionosféricas precursoras de eventos sísmicos [14].
- **Salud y biomedicina:** diagnóstico de enfermedades cardiovasculares, trastornos cognitivos y predicción de reacciones adversas a medicamentos [24] [10].
- **Análisis de texto y minería de opiniones:** clasificación de contenido tóxico y análisis de sentimiento en redes sociales [2] [20] [25].
- **Seguridad vial:** detección de comportamientos de conducción de riesgo mediante sensores vehiculares [26].
- **Ingeniería de software:** predicción de defectos en código fuente bajo condiciones de desbalance extremo [27].
- **Sistemas de recomendación:** personalización dinámica de contenidos educativos [28].
- **Visión artificial y procesamiento de señales:** reconocimiento de gestos, seguimiento de objetos y estimación de dirección de llegada de señales [17] [29] [18].

Los estudios revisados muestran que AdaBoost suele alcanzar altos niveles de precisión en problemas de clasificación, especialmente cuando se combina con técnicas de optimización o aprendizaje profundo. Sin embargo, los costos computacionales pueden incrementarse significativamente en arquitecturas híbridas complejas [1, 2].

1.3.6. Comparación de AdaBoost con Otros Métodos Ensemble

La comparación con otros métodos de aprendizaje por conjuntos permite identificar fortalezas y limitaciones específicas. Mientras que AdaBoost sigue una estrategia secuencial orientada principalmente a la reducción del sesgo, métodos como Bagging y Random Forest utilizan procesos paralelos enfocados en disminuir la varianza mediante el promedio de múltiples modelos independientes [1, 2].

Asimismo, AdaBoost suele emplear árboles de decisión de baja profundidad como clasificadores base, mientras que Random Forest utiliza árboles profundos construidos mediante remuestreo Bootstrap y selección aleatoria de atributos.

En términos de robustez, Random Forest presenta un mejor comportamiento frente al ruido y al desbalance de clases. No obstante, AdaBoost suele obtener mejores resultados cuando los datos son relativamente limpios y el problema requiere una frontera de decisión más refinada [1, 22].

1.3.7. Tendencias de Investigación y Líneas Futuras

Las investigaciones recientes muestran una tendencia creciente hacia la integración de AdaBoost con arquitecturas profundas, donde redes neuronales convolucionales, recurrentes o generativas actúan como extractores avanzados de características y AdaBoost funciona como clasificador final [7] [15] [19].

Otra línea de investigación relevante se centra en la utilización de algoritmos evolutivos para optimizar automáticamente la selección de características, el número de clasificadores y los hiperparámetros del ensamble. Estas estrategias buscan mejorar simultáneamente la diversidad, la precisión y la eficiencia computacional, favoreciendo la implementación de sistemas inteligentes en entornos con recursos limitados [10] [23].

Tabla 1.1: Principales líneas de optimización de AdaBoost identificadas en la literatura.

Línea	Técnica	Objetivo
Deep Learning	CNN, LSTM, GAN	Mejorar extracción de características
Ruido	SPL, AMWSPLAdaBoost	Reducir sobreajuste
Desbalance	SMOTE, ENN	Equilibrar clases
Metaheurísticas	EVAdaBoost, SSA	Optimizar parámetros
Híbridos	AdaBoost + RF + GB	Incrementar diversidad

1.3.8. AdaBoost en Aprendizaje Semisupervisado y Optimización Metaheurística

Un avance notable es la integración de AdaBoost en entornos semisupervisados para la detección de nódulos pulmonares. El modelo *AdaBoost-ISSA-S4VM* utiliza Máquinas de Vectores de Soporte Seguras (S4VM) como clasificadores débiles para manejar simultáneamente datos etiquetados y no etiquetados [4].

Para resolver el problema de la caída en óptimos locales, se emplea el Algoritmo de Búsqueda de Gorrión (SSA) optimizado mediante funciones seno-coseno (SCA), el cual ajusta automáti-

camente los pesos de los clasificadores y los parámetros del modelo. Esta hibridación permite mejorar la precisión hasta en un 21 por ciento frente a modelos SVM tradicionales en aplicaciones de imágenes médicas [9].

1.3.9. Uso de Broad Learning Systems (BLS) como Aprendices Débiles

Frente a las redes de aprendizaje profundo que requieren un ajuste masivo de hiperparámetros, los Broad Learning Systems (BLS) emergen como una alternativa eficiente para actuar como clasificadores débiles dentro del marco de AdaBoost.

A diferencia de los modelos profundos, el BLS expande su estructura de red de forma incremental, lo que facilita una extracción de características dinámica y una adaptación rápida a datos de alta dimensionalidad. En la detección de depresión mediante señales de voz, el marco *EVAdaBoost* utiliza mecanismos evolutivos para maximizar la diversidad entre modelos BLS, permitiendo que cada aprendiz se especialice en diferentes fronteras de decisión y tipos de señales, incluyendo transformadas de Fourier, Wavelet y características extraídas mediante CNN [30].

1.3.10. Aplicaciones en Procesamiento de Señales de Un Bit y Sensado Comprimido

AdaBoost ha trascendido la clasificación de datos tabulares para incorporarse al procesamiento avanzado de señales. El modelo *CS-AdaBoost* aplica el esquema de boosting para la estimación de la Dirección de Llegada (DOA) en sistemas que utilizan conversores analógico-digitales (ADC) de un bit.

Mediante un clasificador débil de dos etapas, compuesto por una estimación ponderada de la norma ℓ_2 y un operador de umbral duro (*hard-thresholding*), el sistema impone condiciones de dispersión (*sparsity*) para recuperar la matriz de señal de la fuente incluso en escenarios con fuentes altamente correlacionadas [20].

1.3.11. Justicia Algorítmica y Reducción de Sesgo en el Boosting

La optimización moderna de AdaBoost no solo persigue una mayor precisión, sino también una mayor equidad en la toma de decisiones. El marco *SMOTEHashBoost* aborda el problema del sesgo algorítmico mediante técnicas de submuestreo (*undersampling*) basadas en hashing [31].

Esta metodología proyecta los datos a espacios de menor dimensionalidad y utiliza funciones hash para seleccionar muestras representativas de la clase mayoritaria de forma uniforme. Al combinar este procedimiento con técnicas de sobremuestreo sintético como SMOTE, AdaBoost puede entrenar clasificadores débiles sobre subconjuntos más equilibrados, preservando la diversidad de las características originales y reduciendo la tendencia del modelo a favorecer excesivamente a la clase predominante [16].

1.3.12. Aplicaciones en Procesamiento de Lenguaje Natural (NLP)

En tareas de clasificación de comentarios tóxicos y análisis de sentimiento, se han propuesto ensambles híbridos, como el modelo *CommentClass*, que combinan AdaBoost con algoritmos como Random Forest y Support Vector Machines (SVM) [17].

1.3.13. Técnica de votación

Estos modelos emplean estrategias de *soft-voting* y promediado para combinar las probabilidades de clasificación generadas por AdaBoost y los demás clasificadores. Gracias a ello, se han alcanzado precisiones de hasta el 97.96 % en plataformas como YouTube, complementando el proceso con técnicas de normalización de texto tales como *stemming* y *lemmatization* [25].

1.3.14. Resumen de Variables Clave

Tabla 1.2: Variables clave utilizadas en AdaBoost

Variable	Función en el algoritmo
D_t	Determina la prioridad o peso asignado a las muestras en cada iteración.
α_t	Representa el peso del clasificador débil en la decisión final del modelo.
MCDI	Índice propuesto para medir la gravedad de una mala clasificación.
SPL Regularizer	Mecanismo que filtra el ruido y mejora la robustez del algoritmo.

1.4. Conclusiones

El algoritmo AdaBoost continúa siendo una herramienta fundamental en el desarrollo de sistemas inteligentes debido a su elegancia matemática y su capacidad demostrada para fortalecer clasificadores débiles. No obstante, su transición desde la teoría a entornos de datos reales y ruidosos ha exigido una evolución significativa de sus mecanismos internos.

El algoritmo AdaBoost permanece como una pieza central en la inteligencia artificial debido a su capacidad para fortalecer modelos débiles mediante una reponderación iterativa precisa. No obstante, su transición hacia aplicaciones industriales y médicas críticas ha exigido una evolución técnica significativa. La integración de funciones de pérdida robustas, la hibridación con arquitecturas de aprendizaje profundo y la automatización evolutiva son los pilares que permiten a AdaBoost superar sus limitaciones históricas ante el ruido y el desbalance. En conclusión, la optimización de AdaBoost no es solo un reto matemático, sino una necesidad operativa para la construcción de sistemas inteligentes más fiables, interpretables y escalables.

Referencias

- [1] H. F. Gouda and F. D. Abdallah, “Comparative performance of bagging and boosting ensemble models for predicting lumpy skin disease with multiclass-imbalanced data,” *Scientific Reports*, vol. 15, 12 2025. doi:10.1038/s41598-025-23846-7.
- [2] Y. Wang and L. Feng, “New bagging based ensemble learning algorithm distinguishing short and long texts for document classification,” *ACM Transactions on Asian and Low-Resource Language Information Processing*, vol. 24, 3 2025. doi:10.1145/3718740.
- [3] M. A. Carreira-Perpiñán and A. Zharmagambetov, “Ensembles of bagged tao trees consistently improve over random forests, adaboost and gradient boosting,” in *FODS 2020 - Proceedings of the 2020 ACM-IMS Foundations of Data Science Conference*, pp. 35–46, Association for Computing Machinery, Inc, 10 2020. doi:10.1145/3412815.3416882.
- [4] K. H. Ahmed, S. Axelsson, Y. Li, and A. M. Sagheer, “A credit card fraud detection approach based on ensemble machine learning classifier with hybrid data sampling,” *Machine Learning with Applications*, vol. 20, p. 100675, 6 2025. doi:10.1016/j.mlwa.2025.100675.
- [5] W. Ning, S. Chen, S. Lei, and X. Liao, “Amwspladaboost credit card fraud detection method based on enhanced base classifier diversity,” *IEEE Access*, vol. 11, pp. 66488–66496, 2023. doi:10.1109/ACCESS.2023.3290957.
- [6] S. Yadav, D. Joshi, S. Mulye, S. S. Udmale, and G. P. Bhole, “Smotehashboost: Ensemble algorithm for imbalanced dataset pattern classification,” *IEEE Access*, vol. 13, pp. 58092–58107, 2025. doi:10.1109/ACCESS.2025.3555565.
- [7] H. H. Sulimani, “Adaboost-lstm: A hybrid ensemble framework for sequential credit card fraud detection,” *IEEE Access*, vol. 13, pp. 212504–212516, 2025. doi:10.1109/ACCESS.2025.3642207.
- [8] W. Muhammad, H. Khan, T. Kamal, D. Ahn, and K. Y. Oh, “Intelligent troubleshooting of vertical bandsaws, leveraging ensemble learning on low-level data,” *IEEE Access*, vol. 12, pp. 171280–171294, 2024. doi:10.1109/ACCESS.2024.3498951.
- [9] S. Liu, C. Zhang, S. Song, C. Bian, and Y. Xing, “A study on sentence prediction for intentional injury crimes based on adaboost ensemble learning,” pp. 390–396, Association for Computing Machinery (ACM), 11 2025. doi:10.1145/3784013.3784075.
- [10] R. Sayeri, B. Barzegar, Y. B. rad, N. Mikaeilvand, and M. H. T. Najaran, “Evolutionary ada-boost ensemble: A machine learning framework for depression detection,” *Machine Learning with Applications*, vol. 22, p. 100748, 12 2025. doi:10.1016/j.mlwa.2025.100748.
- [11] H. Xu and H. Yuan, “An svm-based adaboost cascade classifier for sonar image,” *IEEE Access*, vol. 8, pp. 115857–115864, 2020. doi:10.1109/ACCESS.2020.3004473.

- [12] Y. Zhang, G. Zhang, T. Huang, Y. Liu, and N. Hu, “Adaboost model for rockburst intensity prediction considering class differences and quantitative characterization of misclassification difference,” *Scientific Reports*, vol. 14, 12 2024. doi:10.1038/s41598-024-79141-4.
- [13] D. Wall, S. K. Taraman, B. Vaughan, and A. Abbas, “Us₁1862339_b2₁33 – 296 – 739 – 323 – 245,” *OficinadePatentesyMarcasdeEE.UU.*, 12024.
- [14] S. Karatay, Z. Mantaroglu, and E. N. Serbetli, “Adaboost-powered multi-class classification of pre-earthquake ionospheric anomalies using gnss network in türkiye: A comparison with random forest,” *Earth Science Informatics*, vol. 19, 5 2026. doi:10.1007/s12145-026-02109-7.
- [15] M. Xu, P. Baraldi, X. Lu, and E. Zio, “Generative adversarial networks with adaboost ensemble learning for anomaly detection in high-speed train automatic doors,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 23, pp. 23408–23421, 12 2022. doi:10.1109/TITS.2022.3203871.
- [16] B. Cai, M. Li, H. Yang, C. Wang, and Y. Chen, “State of charge estimation of lithium-ion battery based on back propagation neural network and adaboost algorithm,” *Energies*, vol. 16, 12 2023. doi:10.3390/en16237824.
- [17] M. Esfandiari, P. Pulkkinen, S. A. Vorobyov, and V. Koivunen, “Cs-adaboost: One-bit compressed sensing for direction-of-arrival estimation,” pp. 2097–2101, Institute of Electrical and Electronics Engineers (IEEE), 12 2025. doi:10.23919/eusipco63237.2025.11226108.
- [18] Y. Li, X. Gao, and Y. Zhang, “Detection and strong classification of natural weld defects by magneto-optical imaging under rotating magnetic field excitation,” *IEEE Access*, vol. 12, pp. 161805–161819, 2024. doi:10.1109/ACCESS.2024.3488718.
- [19] S. Nirmal, P. Patil, and J. R. R. Kumar, “Cnn-adaboost based hybrid model for electricity theft detection in smart grid,” *e-Prime - Advances in Electrical Engineering, Electronics and Energy*, vol. 7, 3 2024. doi:10.1016/j.prime.2024.100452.
- [20] M. M. Rahman, A. I. Shiplu, and Y. Watanobe, “Commentclass: A robust ensemble machine learning model for comment classification,” *International Journal of Computational Intelligence Systems*, vol. 17, 12 2024. doi:10.1007/s44196-024-00589-3.
- [21] W. Guo, Z. Luo, H. Chen, F. Hang, J. Zhang, and H. A. Bayatti, “Adaboost algorithm in trustworthy network for anomaly intrusion detection,” *Applied Mathematics and Nonlinear Sciences*, vol. 8, pp. 1819–1830, 1 2023. doi:10.2478/amns.2022.2.0171.
- [22] C. K. K. Reddy, P. A. Reddy, P. S. Reddy, M. Shuaib, S. Alam, S. Ahmad, and A. Rajaram, “Twined ensemble framework for network security: integrating random forest, adaboost, and gradient boosting for enhanced intrusion detection,” *Discover Internet of Things*, vol. 5, 12 2025. doi:10.1007/s43926-025-00199-1.
- [23] J. Zhang, K. Xia, Z. He, Z. Yin, and S. Wang, “Semi-supervised ensemble classifier with improved sparrow search algorithm and its application in pulmonary nodule detection,” *Mathematical Problems in Engineering*, vol. 2021, 2021. doi:10.1155/2021/6622935.
- [24] N. Tawfik and N. Zayed, “Early cardiovascular disease detection using predictive machine-learning models: Evaluation and insights,” *Journal of Engineering Sciences*, vol. 54, pp. 18–35, 1 2026. doi:10.21608/jesaun.2025.369613.1457.
- [25] B. Gaye, D. Zhang, and A. Wulamu, “A tweet sentiment classification approach using a hybrid stacked ensemble technique,” *Information (Switzerland)*, vol. 12, 9 2021. doi:10.3390/info12090374.

- [26] S. K. Singh and A. Sharma, “Revving up insights: machine learning-based classification of obd ii data and driving behavior analysis using g-force metrics,” *Bulletin of Electrical Engineering and Informatics*, vol. 14, pp. 2188–2197, 6 2025. doi:10.11591/eei.v14i3.9398.
- [27] A. Mehta, A. Kaur, and N. Kaur, “Optimizing software fault prediction using voting ensembles in class imbalance scenarios,” *International Journal of Performability Engineering*, vol. 20, pp. 676–687, 11 2024. doi:10.23940/ijpe.24.11.p4.676687.
- [28] B. Mi, “Optimizing content recommendation system in innovation and entrepreneurship education platform using adaptive boosting algorithm,” in *Proceedings of the 2025 International Conference on Artificial Intelligence and Educational Systems, ICAIES 2025*, pp. 46–51, Association for Computing Machinery, Inc, 7 2025. doi:10.1145/3744367.3744376.
- [29] S. Liang, L. Wang, L. Zhang, and Y. Wu, “Research on recognition of nine kinds of fine gestures based on adaptive adaboost algorithm and multi-feature combination,” *IEEE Access*, vol. 7, pp. 3235–3246, 2019. doi:10.1109/ACCESS.2018.2884773.
- [30] B. Motamedi and B. Villányi, “A predictive analytics approach with bayesian-optimized gentle boosting ensemble models for diabetes diagnosis,” *Computer Methods and Programs in Biomedicine Update*, vol. 7, p. 100184, 1 2025. doi:10.1016/j.cmpbup.2025.100184.
- [31] A. M. Cucos and L. B. Iantovics, “Machine learning-based adverse drug reaction prediction: Model comparisons, feature optimization and generative ai challenges,” in *Procedia Computer Science*, vol. 270, pp. 1139–1148, Elsevier B.V., 2025. doi:10.1016/j.procs.2025.09.235.