

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
1.	Modelado de la Incertidumbre en Sistemas de Diagnóstico Médico mediante Redes Bayesianas	3
1.1.	Introducción	3
1.2.	Fundamentos Teóricos	4
1.3.	Metodología y Análisis de la Literatura	4
1.4.	Conclusiones	4

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 1

Modelado de la Incertidumbre en Sistemas de Diagnóstico Médico mediante Redes Bayesianas

Autor: Bryan Gustavo Troya Velez (bryan.troya@unl.edu.ec)
Técnica asignada: Adaboost

1.1. Introducción

En el panorama actual de la inteligencia artificial y el aprendizaje automático, el procesamiento de grandes volúmenes de datos heterogéneos ha incrementado la necesidad de desarrollar algoritmos capaces de ofrecer no solo altos niveles de precisión, sino también robustez y escalabilidad. En este contexto, el aprendizaje por conjuntos (*ensemble learning*) se ha consolidado como una de las estrategias más efectivas para mejorar el desempeño de los modelos de clasificación, debido a su capacidad para combinar múltiples clasificadores y reducir errores de generalización, sesgo y varianza. Entre los métodos más representativos de esta categoría destaca AdaBoost (*Adaptive Boosting*), algoritmo que transforma un conjunto de aprendices débiles en un clasificador fuerte mediante un proceso iterativo de ajuste de pesos y combinación ponderada de modelos.

El funcionamiento de AdaBoost se basa en una estrategia secuencial de reponderación dinámica de muestras. En cada iteración, el algoritmo incrementa la importancia de aquellas instancias clasificadas incorrectamente por los modelos previos, obligando al nuevo clasificador a concentrarse en los casos más complejos o ambiguos. Posteriormente, cada aprendiz recibe un peso proporcional a su desempeño, permitiendo construir un modelo global más preciso y robusto. Gracias a estas características, AdaBoost ha sido aplicado exitosamente en múltiples dominios, incluyendo la detección de fraude financiero, la clasificación médica basada en señales biométricas, la detección de anomalías en redes y la predicción de riesgos industriales.

No obstante, diversos estudios recientes señalan que AdaBoost presenta una elevada sensibilidad al ruido y a los valores atípicos (*outliers*), debido a que el incremento de pesos sobre muestras mal clasificadas puede provocar sobreajuste y degradación del rendimiento en escenarios reales. Como respuesta a esta limitación, las investigaciones actuales han propuesto la integración de AdaBoost con arquitecturas de aprendizaje profundo, especialmente redes neuronales convolucionales (CNN) y redes de memoria a largo plazo (LSTM), con el objetivo de mejorar la extracción automática de características y el modelado de dependencias temporales.

Asimismo, se han desarrollado variantes híbridas orientadas al manejo de datos desbalanceados y ruidosos mediante técnicas de aprendizaje adaptativo y mecanismos de diversidad local.

Comprender en profundidad los mecanismos internos mediante los cuales AdaBoost optimiza clasificadores débiles resulta fundamental para el diseño de sistemas inteligentes más confiables y eficientes. Por ello, el presente trabajo se enfoca en analizar el funcionamiento del algoritmo AdaBoost, sus principales fortalezas y limitaciones, así como las tendencias recientes relacionadas con modelos híbridos basados en aprendizaje profundo, buscando determinar su efectividad en la mejora de modelos simples para la resolución de problemas complejos de clasificación.

1.2. Fundamentos Teóricos

Una red bayesiana calcula la distribución de probabilidad conjunta mediante la factorización de dependencias condicionales estructuradas en un grafo acíclico dirigido, expresada matemáticamente en la Ecuación 1.1:

$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Padres}(X_i)) \quad (1.1)$$

1.3. Metodología y Análisis de la Literatura

A través de la metodología de jerarquización científica y la extracción de datos de artículos indexados en bases de datos de alto impacto [1], se estructuraron las dimensiones de rendimiento técnico explicadas en la Tabla 1.1.

Tabla 1.1: Dimensiones de análisis en redes probabilísticas clínicas.

Parámetro	Ventaja Tecnológica	Restricción
Cómputo	Consumo mínimo de memoria RAM	Complejidad algorítmica NP-Hard
Explicabilidad	Trazabilidad analítica exacta	Dependencia de expertos de dominio

1.4. Conclusiones

Las técnicas analíticas clásicas analizadas en este volumen proveen una base de explicabilidad matemática robusta, la cual es crucial para auditar las soluciones automatizadas modernas en la ingeniería de software actual.

Referencias

- [1] L. Chamba-Eras, *Metodología de la Investigación en Computación: Una Guía para el Diseño de Sistemas Inteligentes*. Loja, Ecuador: Editorial Universidad Nacional de Loja, 2026.